LearnedFTL: A Learning-based Page-level FTL for Reducing Double Reads in Flash-based SSDs

Shengzhe Wang, Zihang Lin, Suzhen Wu, Hong Jian, Jie Zhang, Bo Mao

Computer Science and Engineering Department, University of Texas at Arlington, Arlington, TX, USA
*School of Computer Science, Peking University

2024 IEEE International Symposium on High-Performance Computer Architecture (HCPA)

2024.08.07

Presentation by Minseong Kim & Dayeon Wee

kms0509@dankook.ac.kr, wida10@dankook.ac.kr

DANKOOK UNIVERSITY

Dankook University System Software Laboratory

Contents

1. Introduction
2. Background and Motivation
3. Design
4. Evaluation
5. Conclusion

1. Introduction

- 3D NAND와 NVMe기술로 SSD 성능 ↑😊
  - But, 기존의 FTL의 **이중읽기 문제로 랜덤읽기 성능 ↓**🥹

- 랜덤 워크로드에 대한 성능을 개선하고자 LearnedFTL을 제안
  - ① LearnedFTL = TPFTL + Learned Index
  - ② In-place 업데이트 선형 모델
  - ③ 가상 PPN (=VPPN)
  - Group-based allocation

2. Background and Motivation

- DFTL
  - 워크로드의 시간적 지역성 활용
  - 성능 유지, 메모리 사용량 ↓
  - 캐시 미스 시, 이중읽기 문제 발생
  - 대표적 예시인 TPFTL: 시간적 및 공간적 지역성을 모두 활용

2. Background and Motivation

CMT = 캐시된 매핑 테이블
GTD = 글로벌 변환 디렉토리

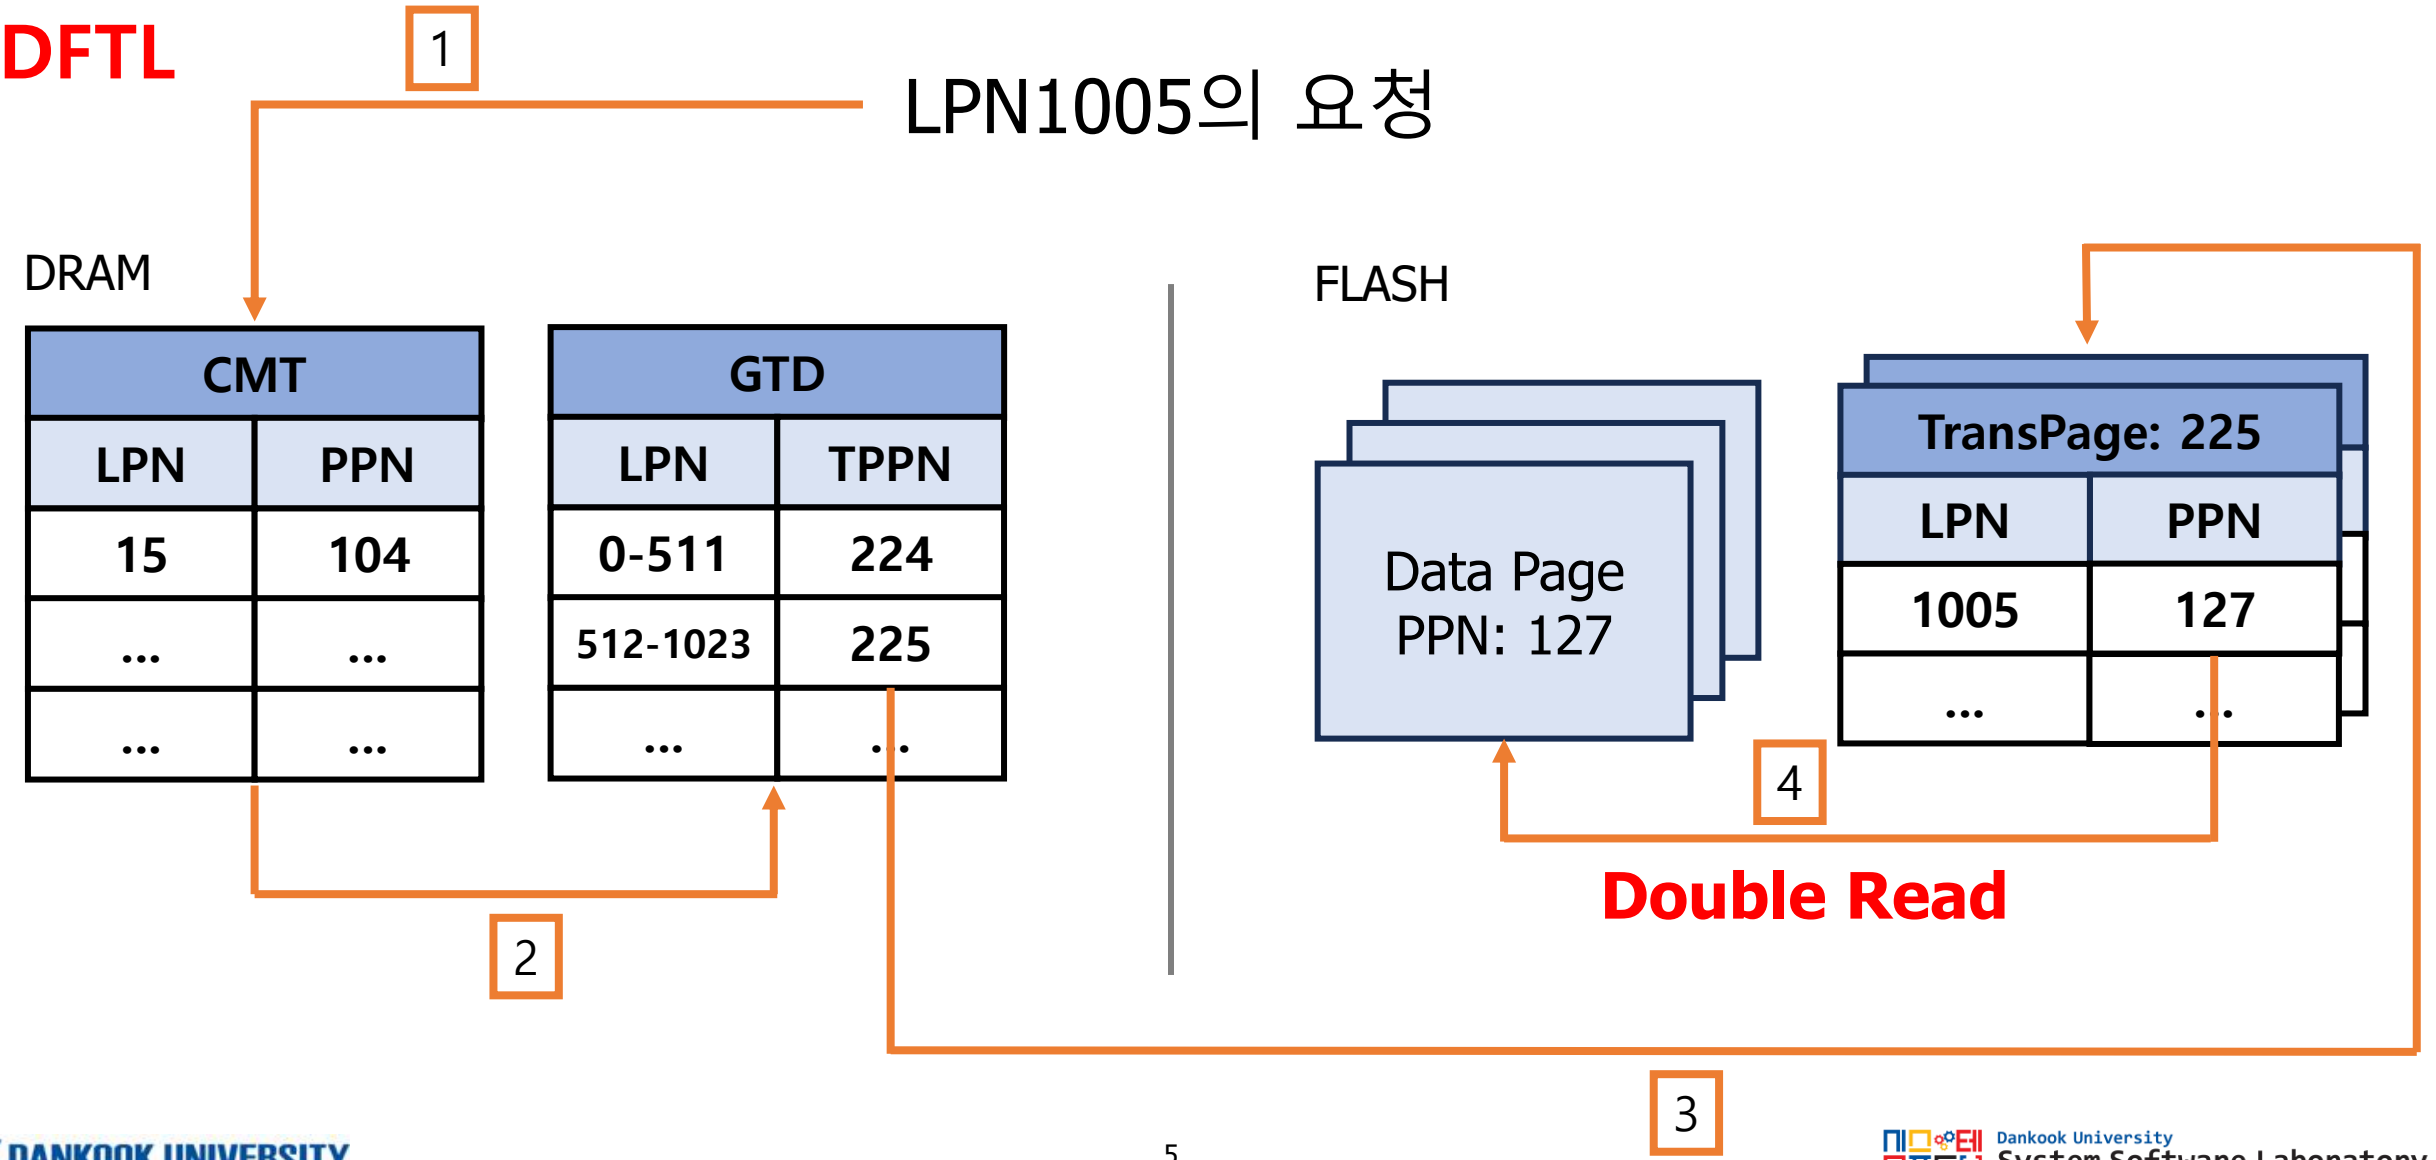

2. Background and Motivation

Approximate Model
Accurate Model

LeaFTL

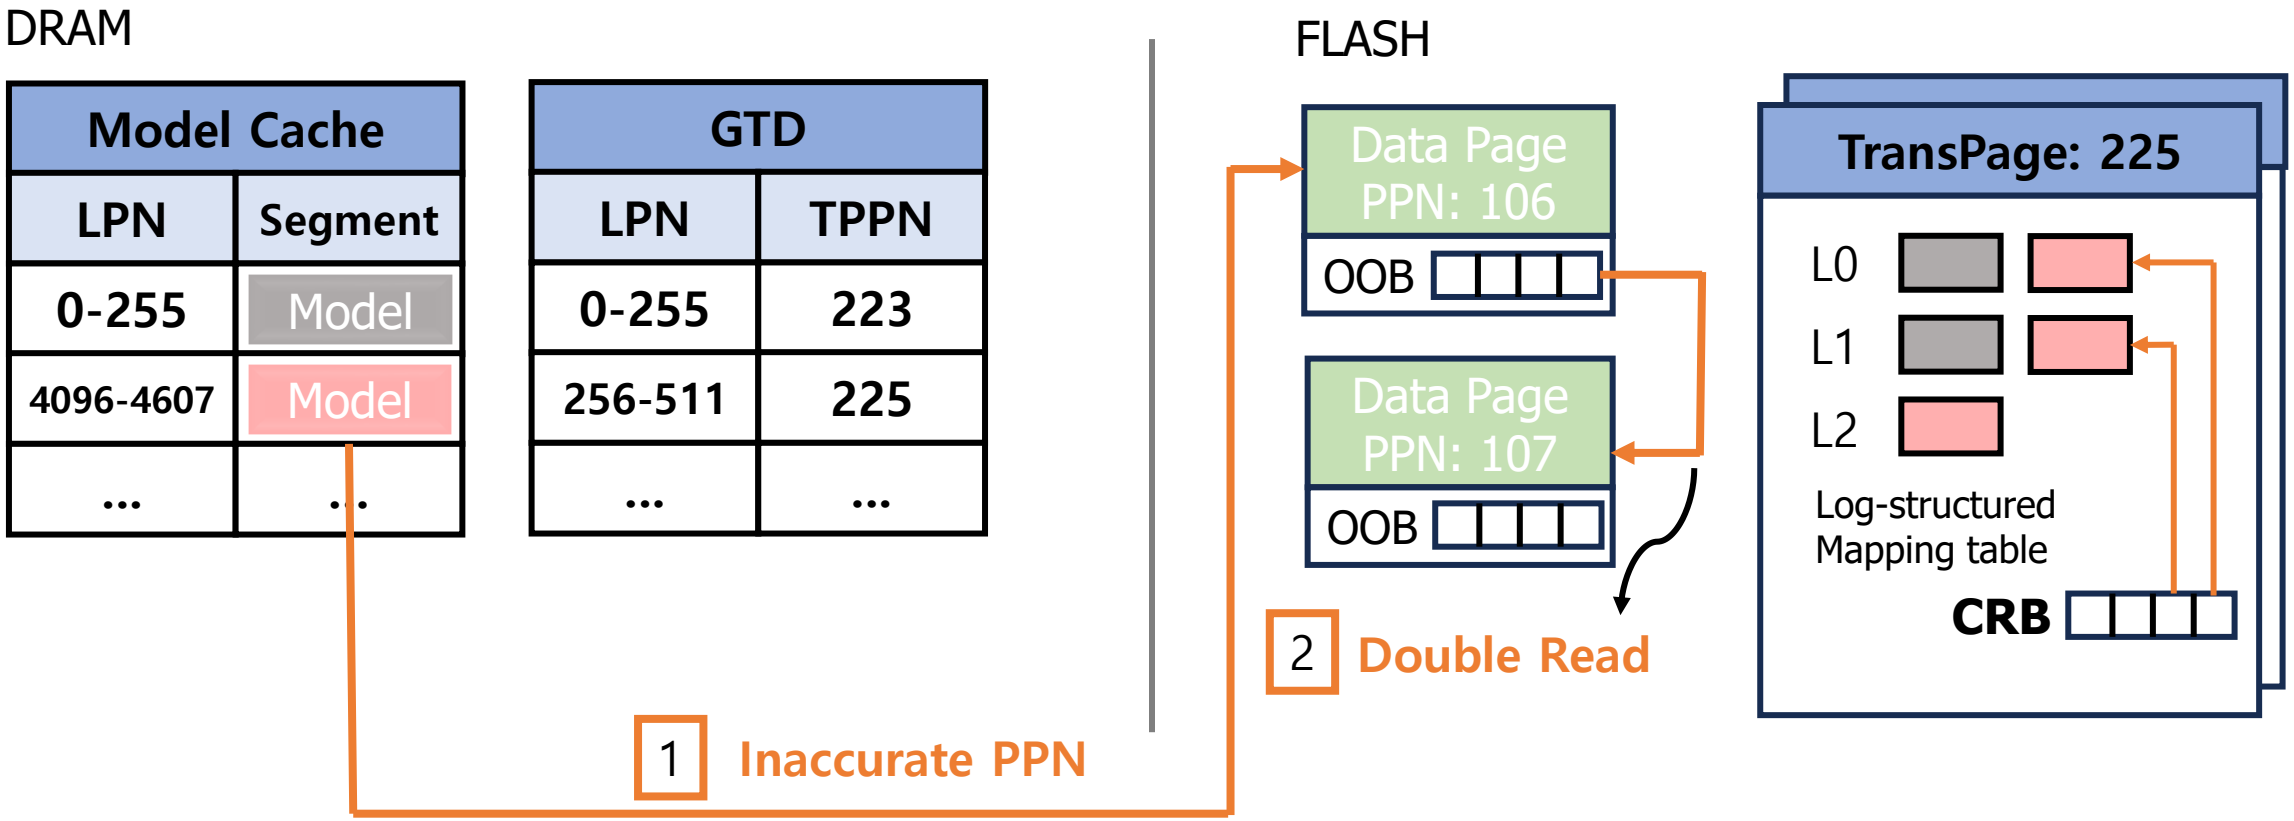

2. Background and Motivation

500배 증가시켰지만
성능이 기대에 못미침

- CMT 크기 증가

  → 성능이 기대만큼 좋진 않음

- 매핑 테이블 압축

  → SSD 쓰기 성능 ↓

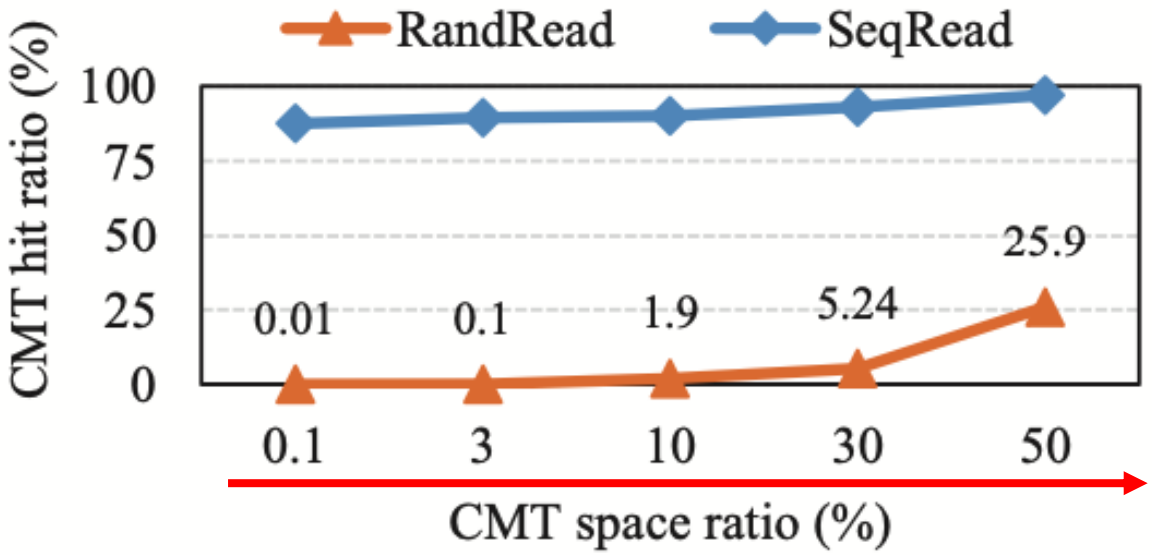

Fig. 3: The hit ratio of TPFTL under different CMT space.

2. Background and Motivation

- Learned Index의 정확성은 주소 변환의 효율성 결정
  - 잘못된 예측은 LeaFTL에서의 이중/삼중읽기 유발
  - 랜덤에서 성능 ↓

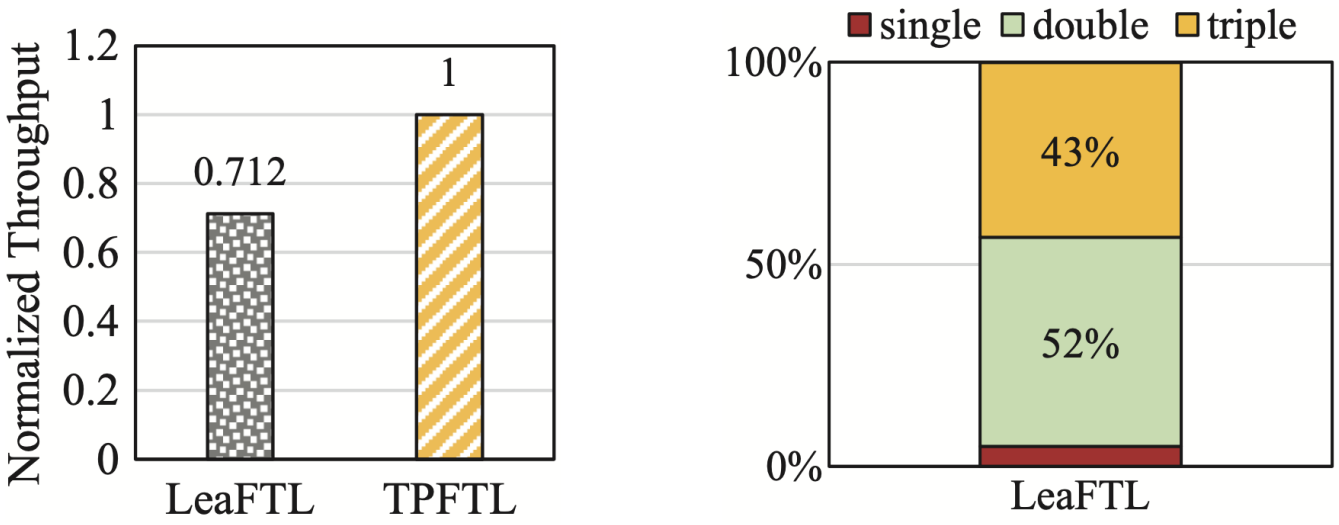

(a) Random read (b) Multi-read count statistics

Fig. 6: The performance results under random reads.

2. Background and Motivation

- LeaFTL에서의 삼중읽기

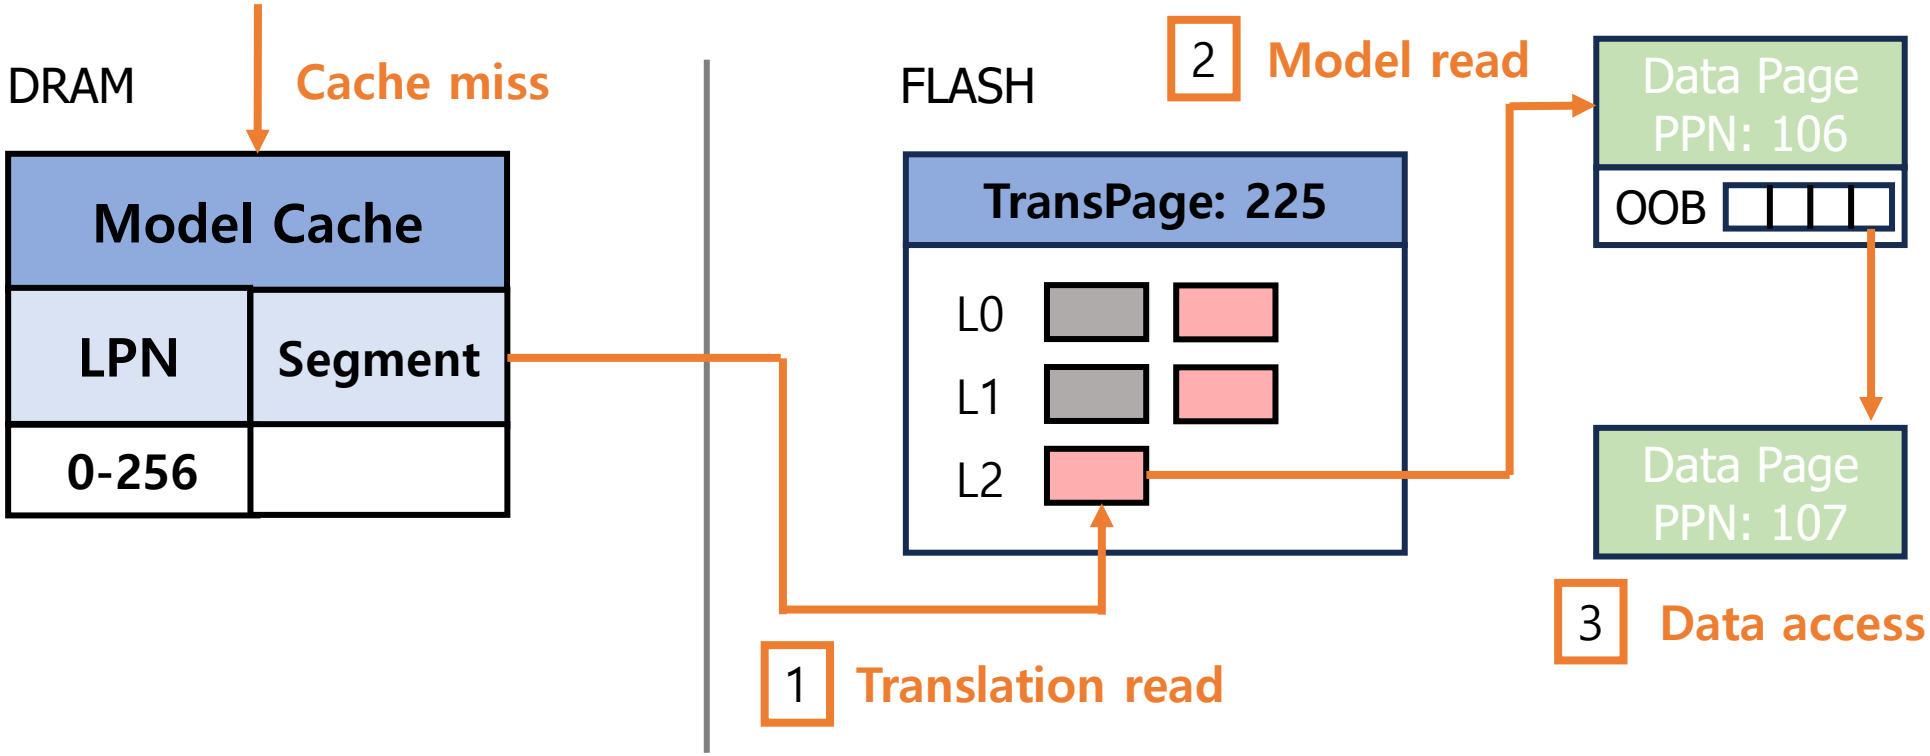

2. Background and Motivation

- TPFTL과 LeaFTL을 세 가지 filebench 워크로드(sequential)에서 비교

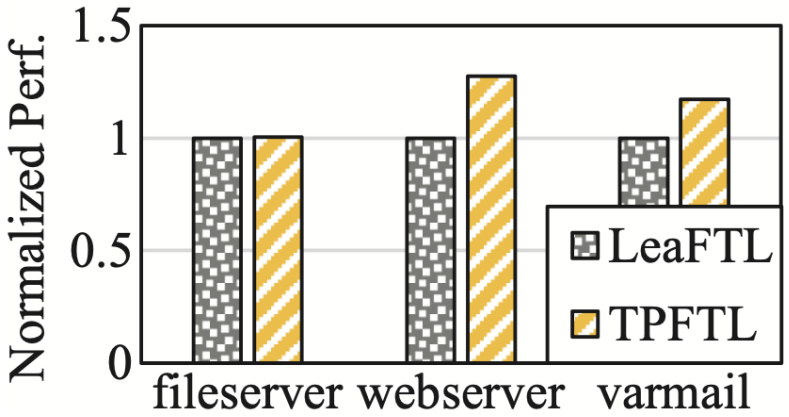

(a) Throughput

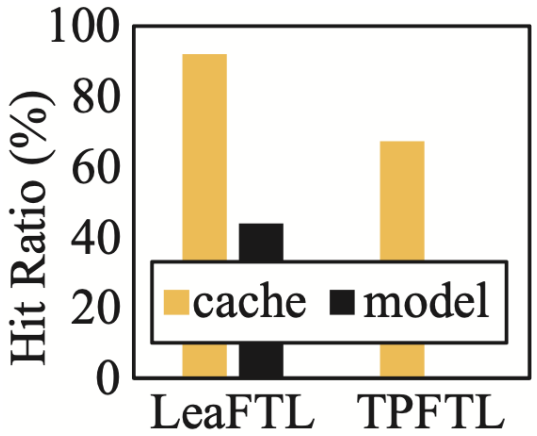

(b) Hit ratio in webserver

LeaFTL

→ Cache는 거의 100% 히트

→ 정확한 건 40%

→ 나머지는 이중/삼중 읽기를 통해 탐색

Fig. 7: The performance of TPFTL and LeaFTL under workloads with high locality.

2. Background and Motivation

- **① 선형 모델과 병렬성 간의 충돌**
  - 내부 병렬성 때문에 연속된 LPN에 연속된 PPN을 할당하기 어려움
  - 선형 모델 훈련 시 SSD의 병렬성을 맞추는 데 문제가 될 수 있음

- **② 학습에서의 오버헤드**
  - 성능 오버헤드
    - 디스크에 쓰는 중에 모델 학습이 실행되면 쓰기 시간 ↑
  - 공간 오버헤드
    - 랜덤 접근에서 수행하게 되면, 인접한 LPN이 물리적으로 분리
    - 모델 학습 시에도 개별 학습 세그먼트로 처리될 수 있음

2. Background and Motivation

- DFTL과 LeaFTL의 한계점
  - 모델 예측의 부정확성
  - 캐시 미스에 따른 성능 저하
  - 모델 업데이트의 어려움
  - 액세스 병렬성과의 충돌

3. Design

- 논문에서 제안하는 것
  - 랜덤 읽기로 인해 발생하는 이중읽기 문제
  - **순차는 DFTL + 랜덤은 Learned Index 활**

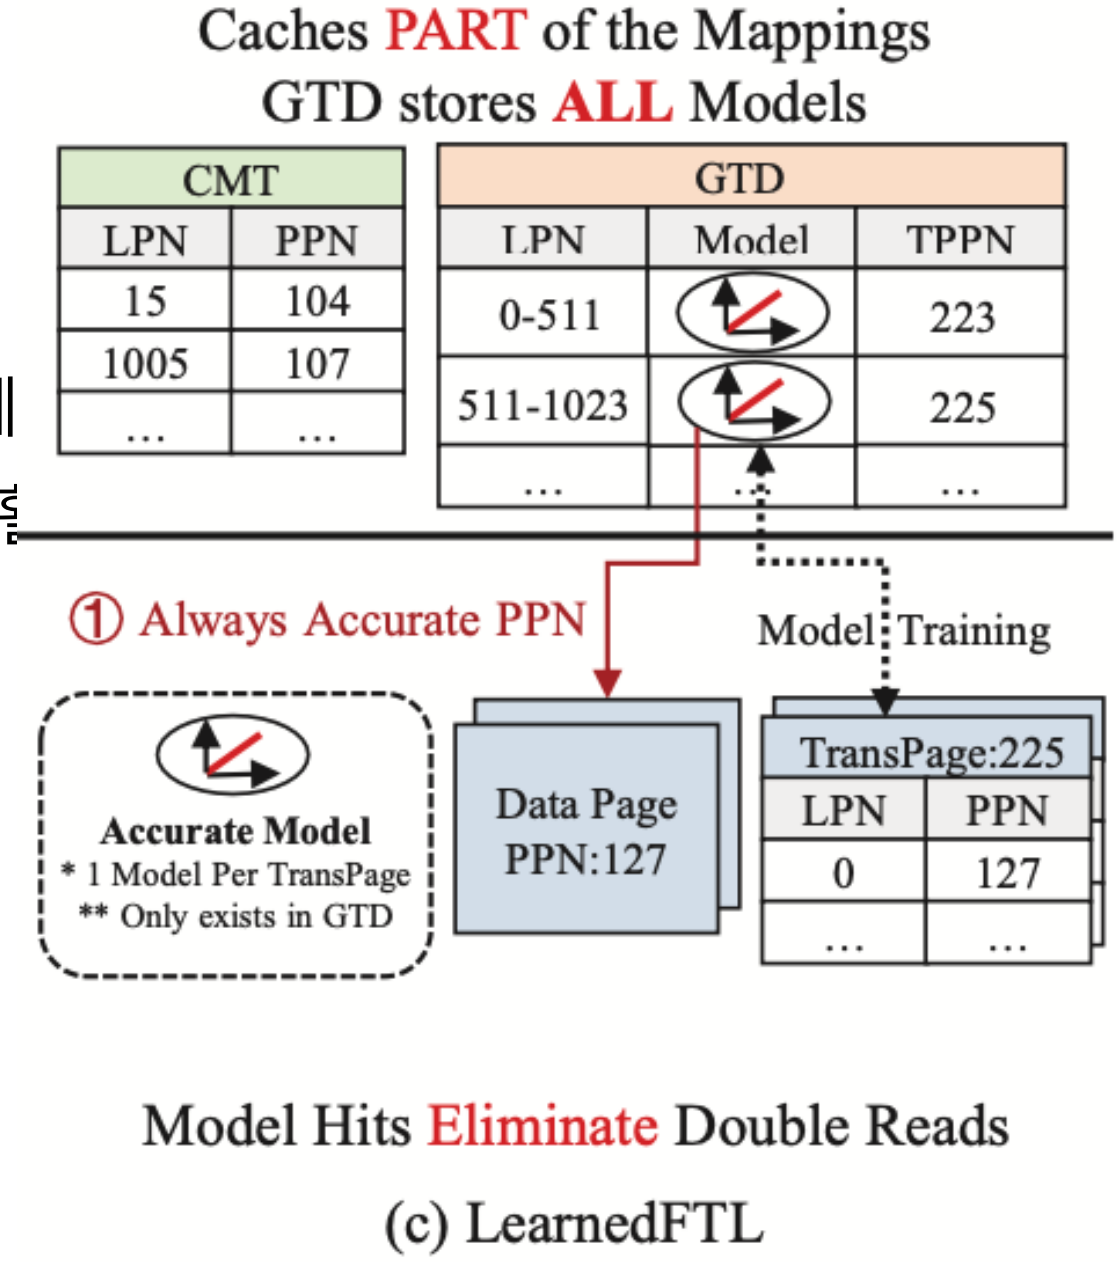

3. Design

- 제안하는 설계방법
  - ① 모델 예측의 정확성 보장
    - 비트맵 사용
  - ② 정렬된 LPN에 대해 연속적인 PPN 얻기
    - 가상 PPN 표현 사용
  - ③ 공간 / 성능 오버헤드 줄이기
    - 그룹 기반 할당 방식
    - 순차 초기화 + GC /재작성을 통한 모델 학습

3. Design

PPN = kn * (LPN - SLPN) + bn

off 을 나타냄

- In
  - <
  - k
  - P

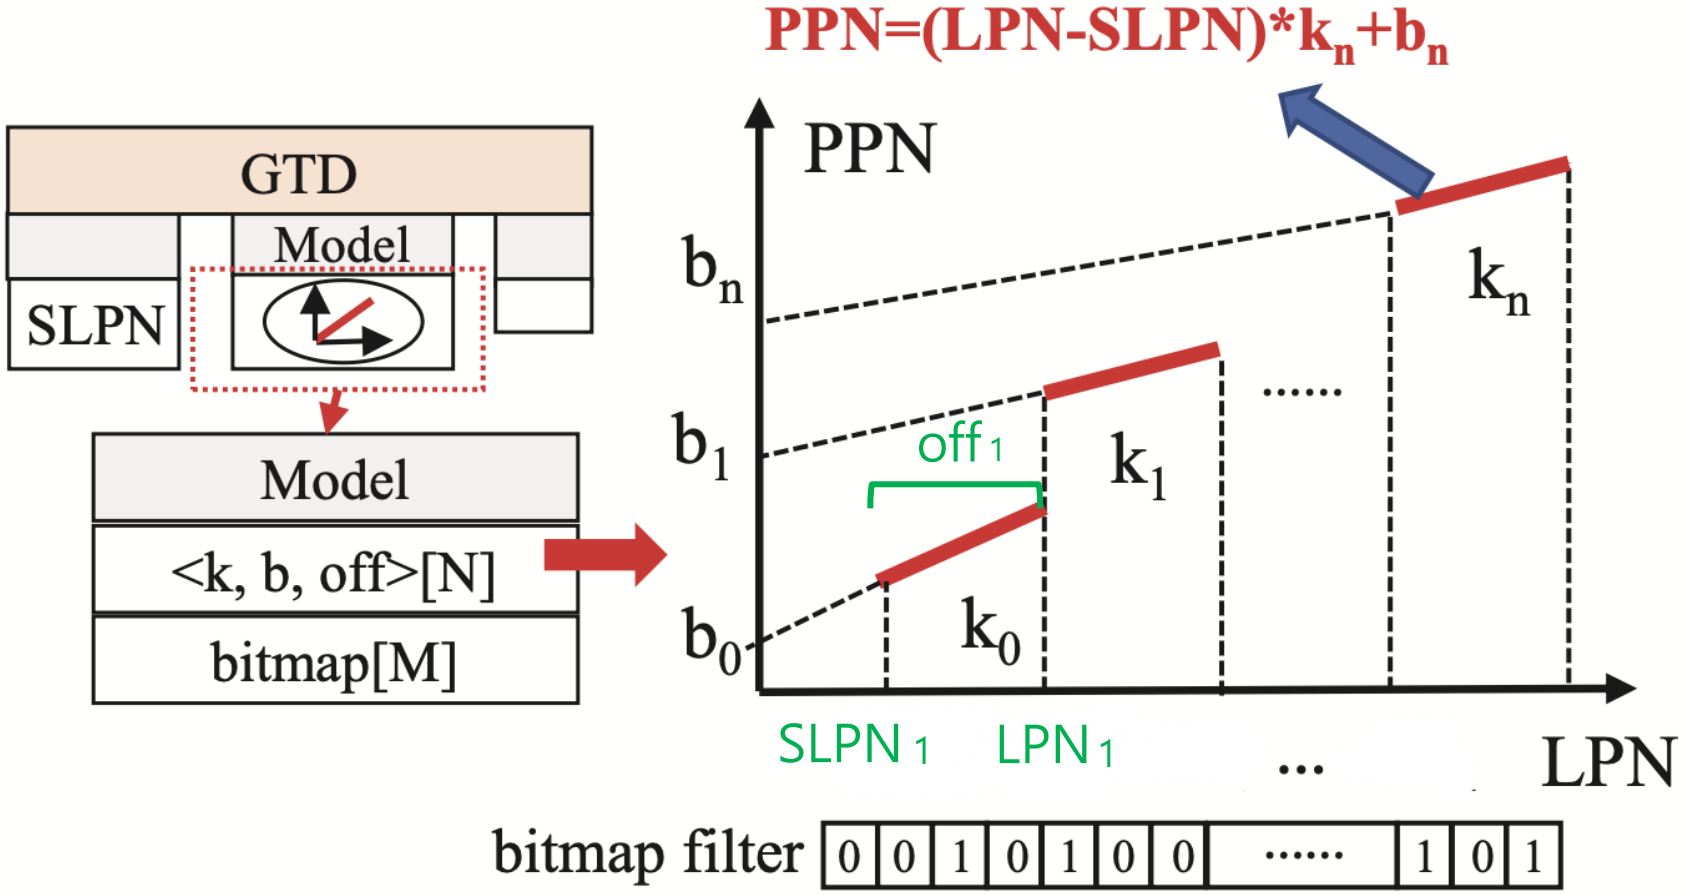

Fig. 8: The structure of an in-place-update model in GTD.

3. Design

- **비트맵 필터**
  - PPN이 정확한지
  - 모델 매개변수 업
  - 데이터 일관성 보
  - 모델 저장 및 재

지

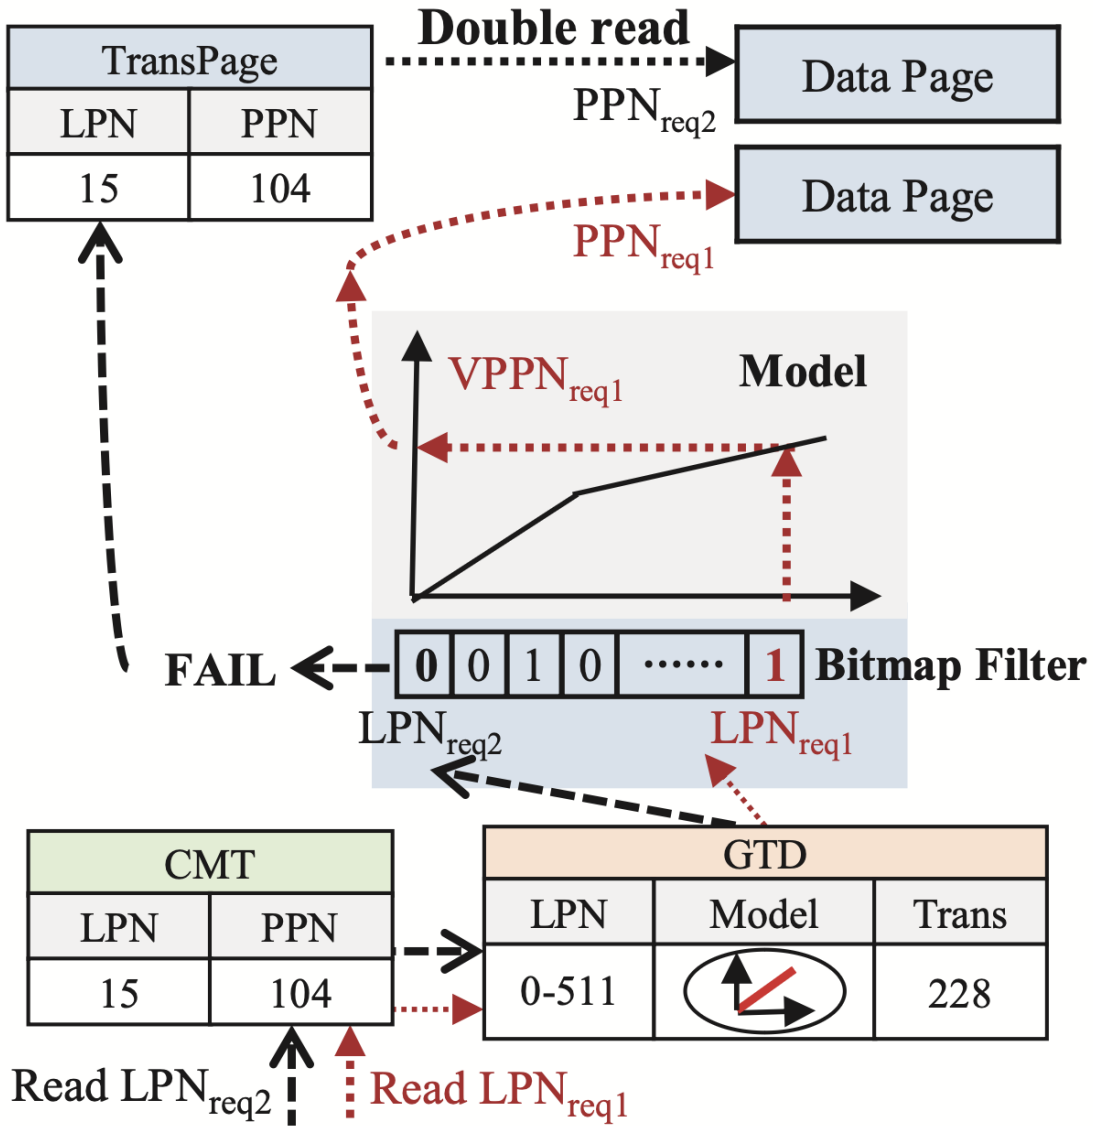

Fig. 9: The workflow of bitmap filter.

3. Design

- In-place 업데이트의 전체 흐름

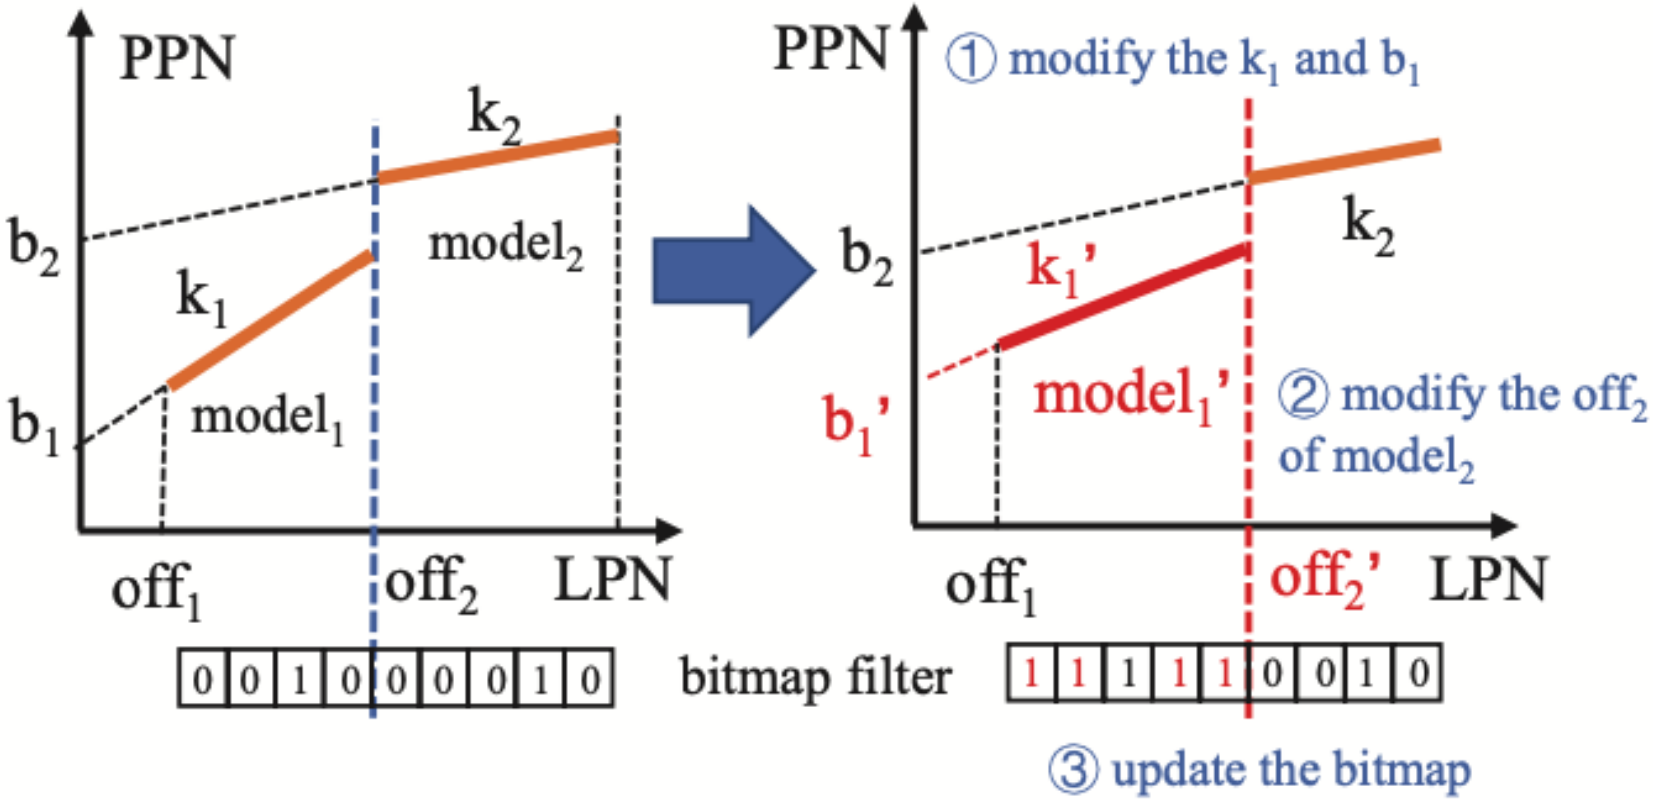

Fig. 10: The workflow of model in-place update.

3. Design

- **Virtual PPN Representation**
  - 연속적인 LPN에 연속적인 PPN을 할당하는 것은 모델 학습의 정확성 향상
  - SSD의 병렬성 때문에 LPN에 연관된 page는 다른 flash chip에 저장
  - PPN 주소 표현 방식이 채널부터 페이지 순으로 계산하여 불연속적인 PPN이 할당
  - 불연속적인 PPN을 연속적인 VPPN으로 변환

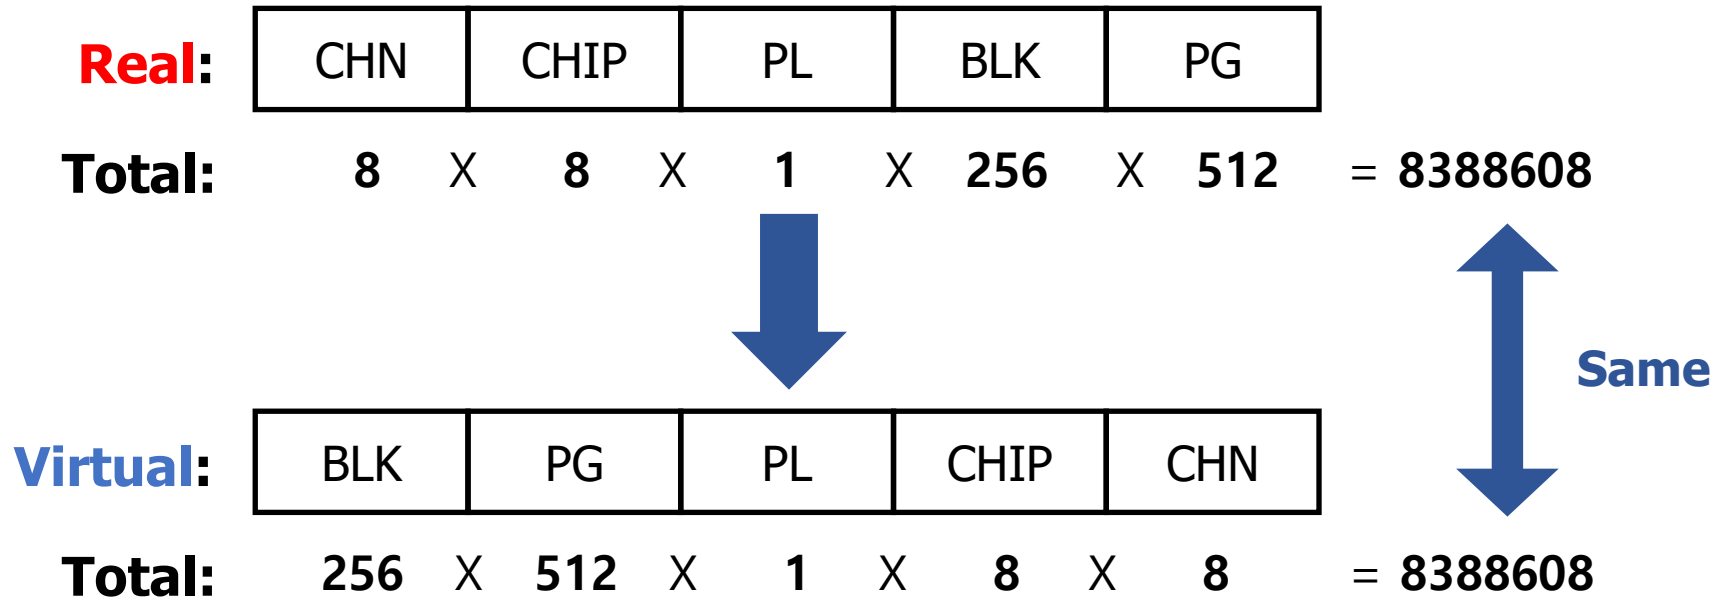

3. Design

기존 방식

8 X 8 X 1 X 256 X 512

1001 4 5 1 64 127 = 5013631

4×(8×1×256×512)+5×(1×256×512)+
1×(256×512)+64×512+127 = 5013631

1002 5 5 1 64 127 = 6062207

1003 6 5 1 64 127 = 7110783

3. Design

기존 방식

LPN	CHN	CHIP	PL	BLK	PG	True PPN
	8	8	1	256	512	
1001	4	5	1	64	127	= 5013631

$4\times(8\times1\times256\times512)+5\times(1\times256\times512)+1\times(256\times512)+64\times512+127 = 5013631$

1002	5	5	1	64	127	= 6062207
1003	6	5	1	64	127	= 7110783

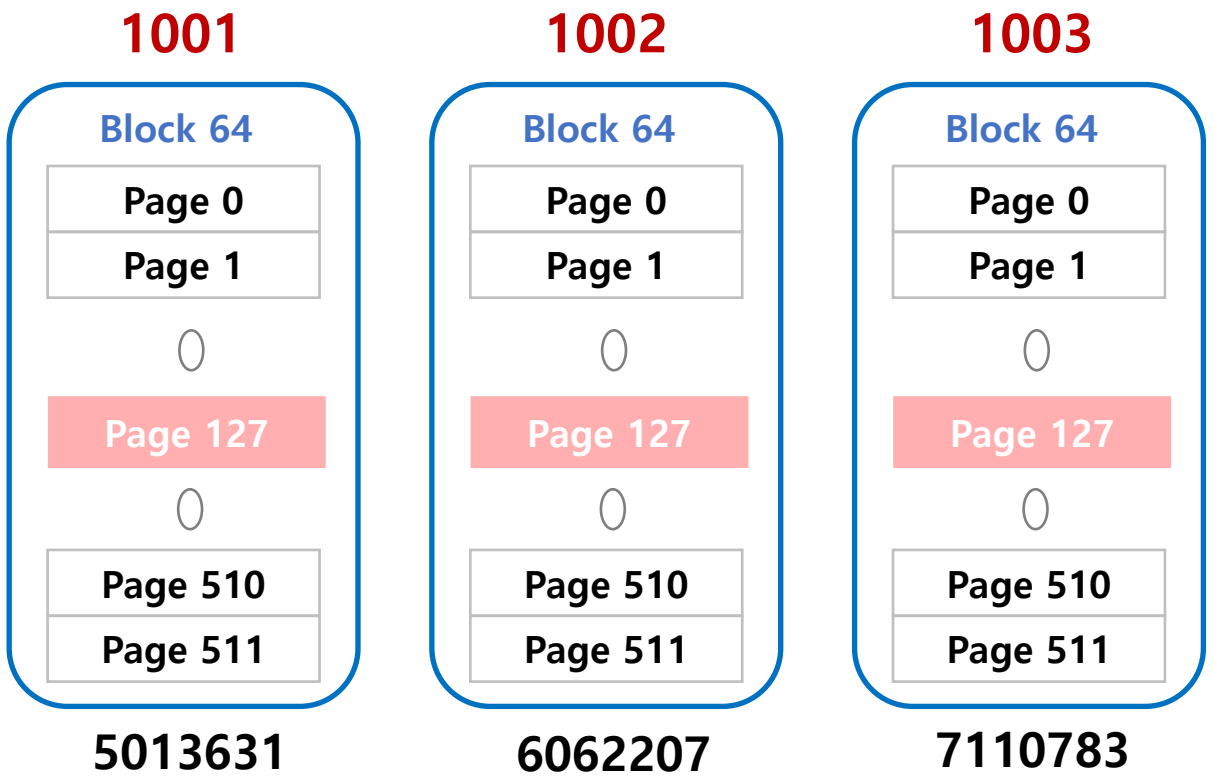

3. Design

기존 방식

LPN	CHN	CHIP	PL	BLK	PG	True PPN
	8	8	1	256	512	
1001	4	5	1	64	127	= 5013631

$4\times(8\times1\times256\times512)+5\times(1\times256\times512)+$
$1\times(256\times512)+64\times512+127 = 5013631$

1002	5	5	1	64	127	= 6062207
1003	6	5	1	64	127	= 7110783

Virtual PPN 적용한 방식

LPN	BLK	PG	PL	CHIP	CHN	VPPN
	8	8	1	256	512	
1001	64	127	1	5	4	= 2105388

$64\times(512\times1\times8\times8)+127\times(1\times8\times8)+$
$1\times(8x8)+5\times8+4 = 2105388$

1002	64	127	1	5	5	= 2105389
1003	64	127	1	5	6	= 2105390

3. Design

- **Group-based Allocation Strategy**
  - Random write에서 많은 불연속적인 LPN 요청이 발생
  - GC를 하며 GTD 항목의 PPN을 재정렬하여 모델 학습이 가능
    - But GTD 항목의 PPN이 다양한 위치에 할당되어 GC시 빈번한 데이터 이동이 발생

3. Design

- **Group-based Allocation Strategy**
  - Random write에서 많은 불연속적인 LPN 요청이 발생
  - GC를 하며 GTD 항목의 PPN을 재정렬하여 모델 학습이 가능
    - But GTD 항목의 PPN이 다양한 위치에 할당되어 GC시 빈번한 데이터 이동이 발생

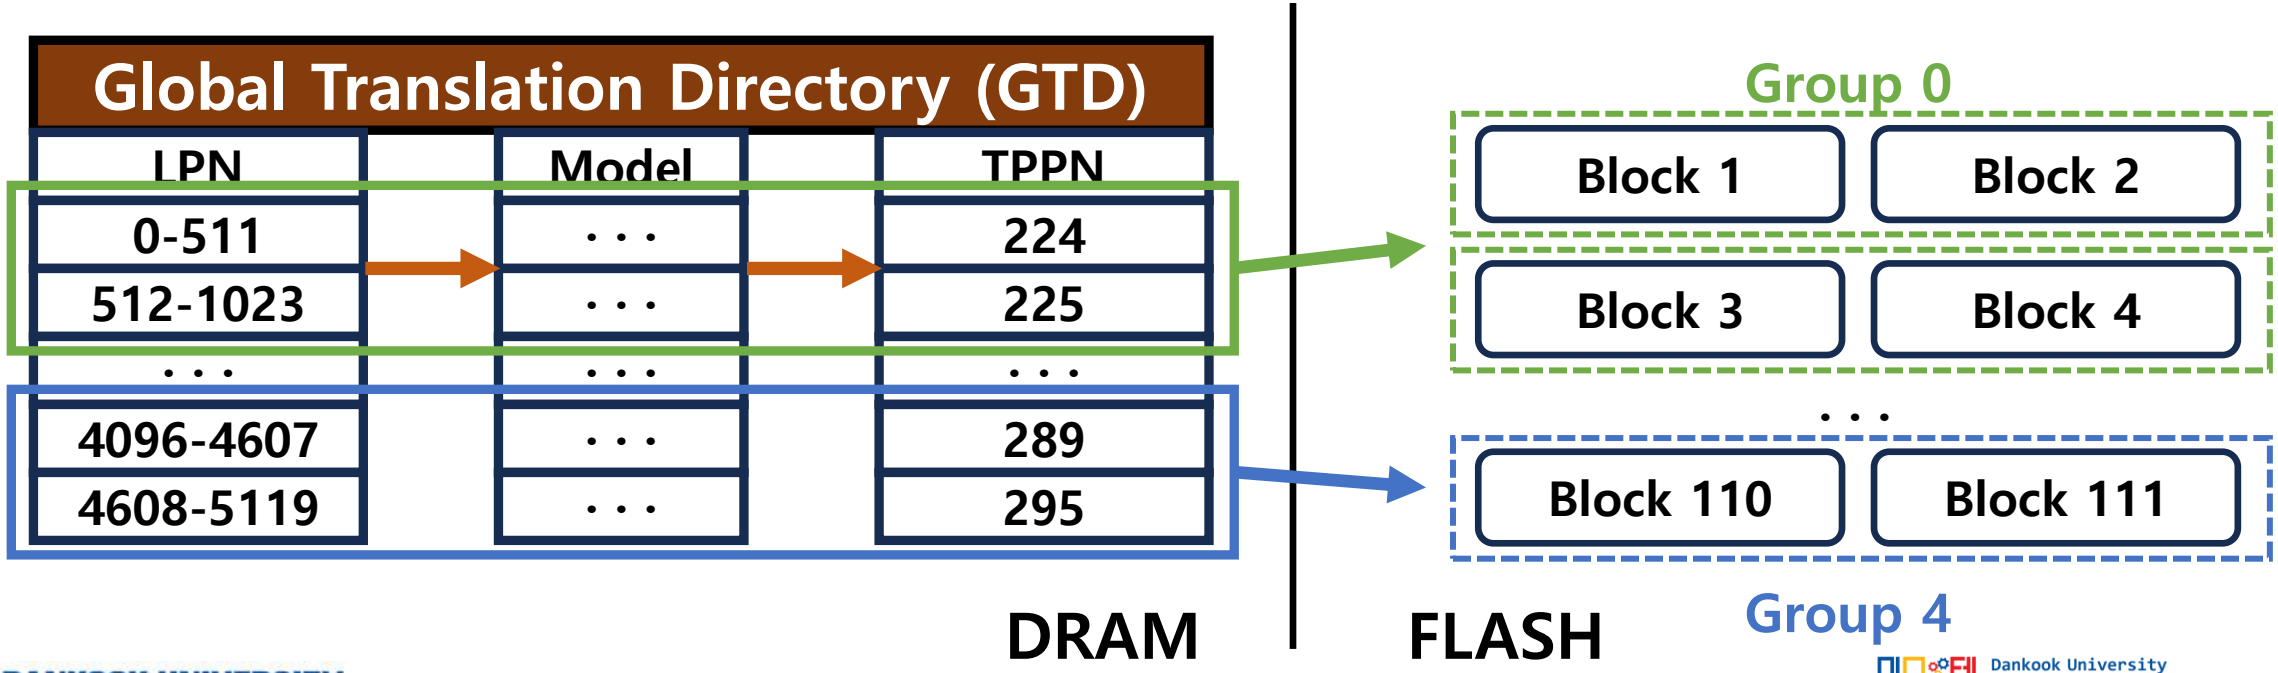

3. Design

- Hot group은 자주 수정되므로 **WAF**가 발생
  - 각 GTD entry group에 global counte를 두어 free page 수를 계산해 hot group을 구분
  - Hot group에 할당할 page가 없는 상황을 해결하기 위해 *Opportunistic cross-group allocation strategy* 사용

- *Opportunistic cross-group allocation strategy*
  - Cold group에 속하는 플래시 블록의 free page를 활용
  - Cold group의 free page를 hot group에 임계값 이상 할당하면 두 그룹이 GC를 작동
  - GC의 performance 향상, WAF 감소, learned index training 보장

3. Design

- Model Training
  - **Sequential Initialization**
    - Sequential write을 기반으로 learned index model을 in-place 업데이트
    - 각 I/O 요청에서 연속적인 LPN-PPN 매핑을 y=x 같은 선형 모델로 업데이트
    - 새로 생성된 모델의 길이(L_{new})가 기존 모델의 길이(L_{old})보다 길면 기존 모델을 업데이트
  - **Model Training via GC**
    - 더 포괄적이고 정확한 모델을 위해 GC를 통한 training 제안
    - GTD entry group의 valid한 page를 LPN순으로 정렬 후 연속적인 PPN을 flash block에 다시 쓰고 이를 기반으로 in-place 업데이트 선형 모델을 학습한다.
    - 그 후 모델을 평가한 후 bitmap filter를 업데이트한다.

4. Evaluation

- 실험 환경

Host setting

CPU	Intel(R) Xeon(R) Gold 5318Y 2.10GHz CPU
DRAM	128GB
OS	Linux kernel 5.4.0

FEMU Setting (SSD emulator)

Parameter	Value	Parameter	Value
Logical SSD	32GB + 2GB(provisioning)	#Page Page Size	512 4KB
#Channel	8	Read latency	40μs
#Chip	8	Write latency	200μs
#Block	256	Erase latency	2ms

4. Evaluation

- GTD Setting

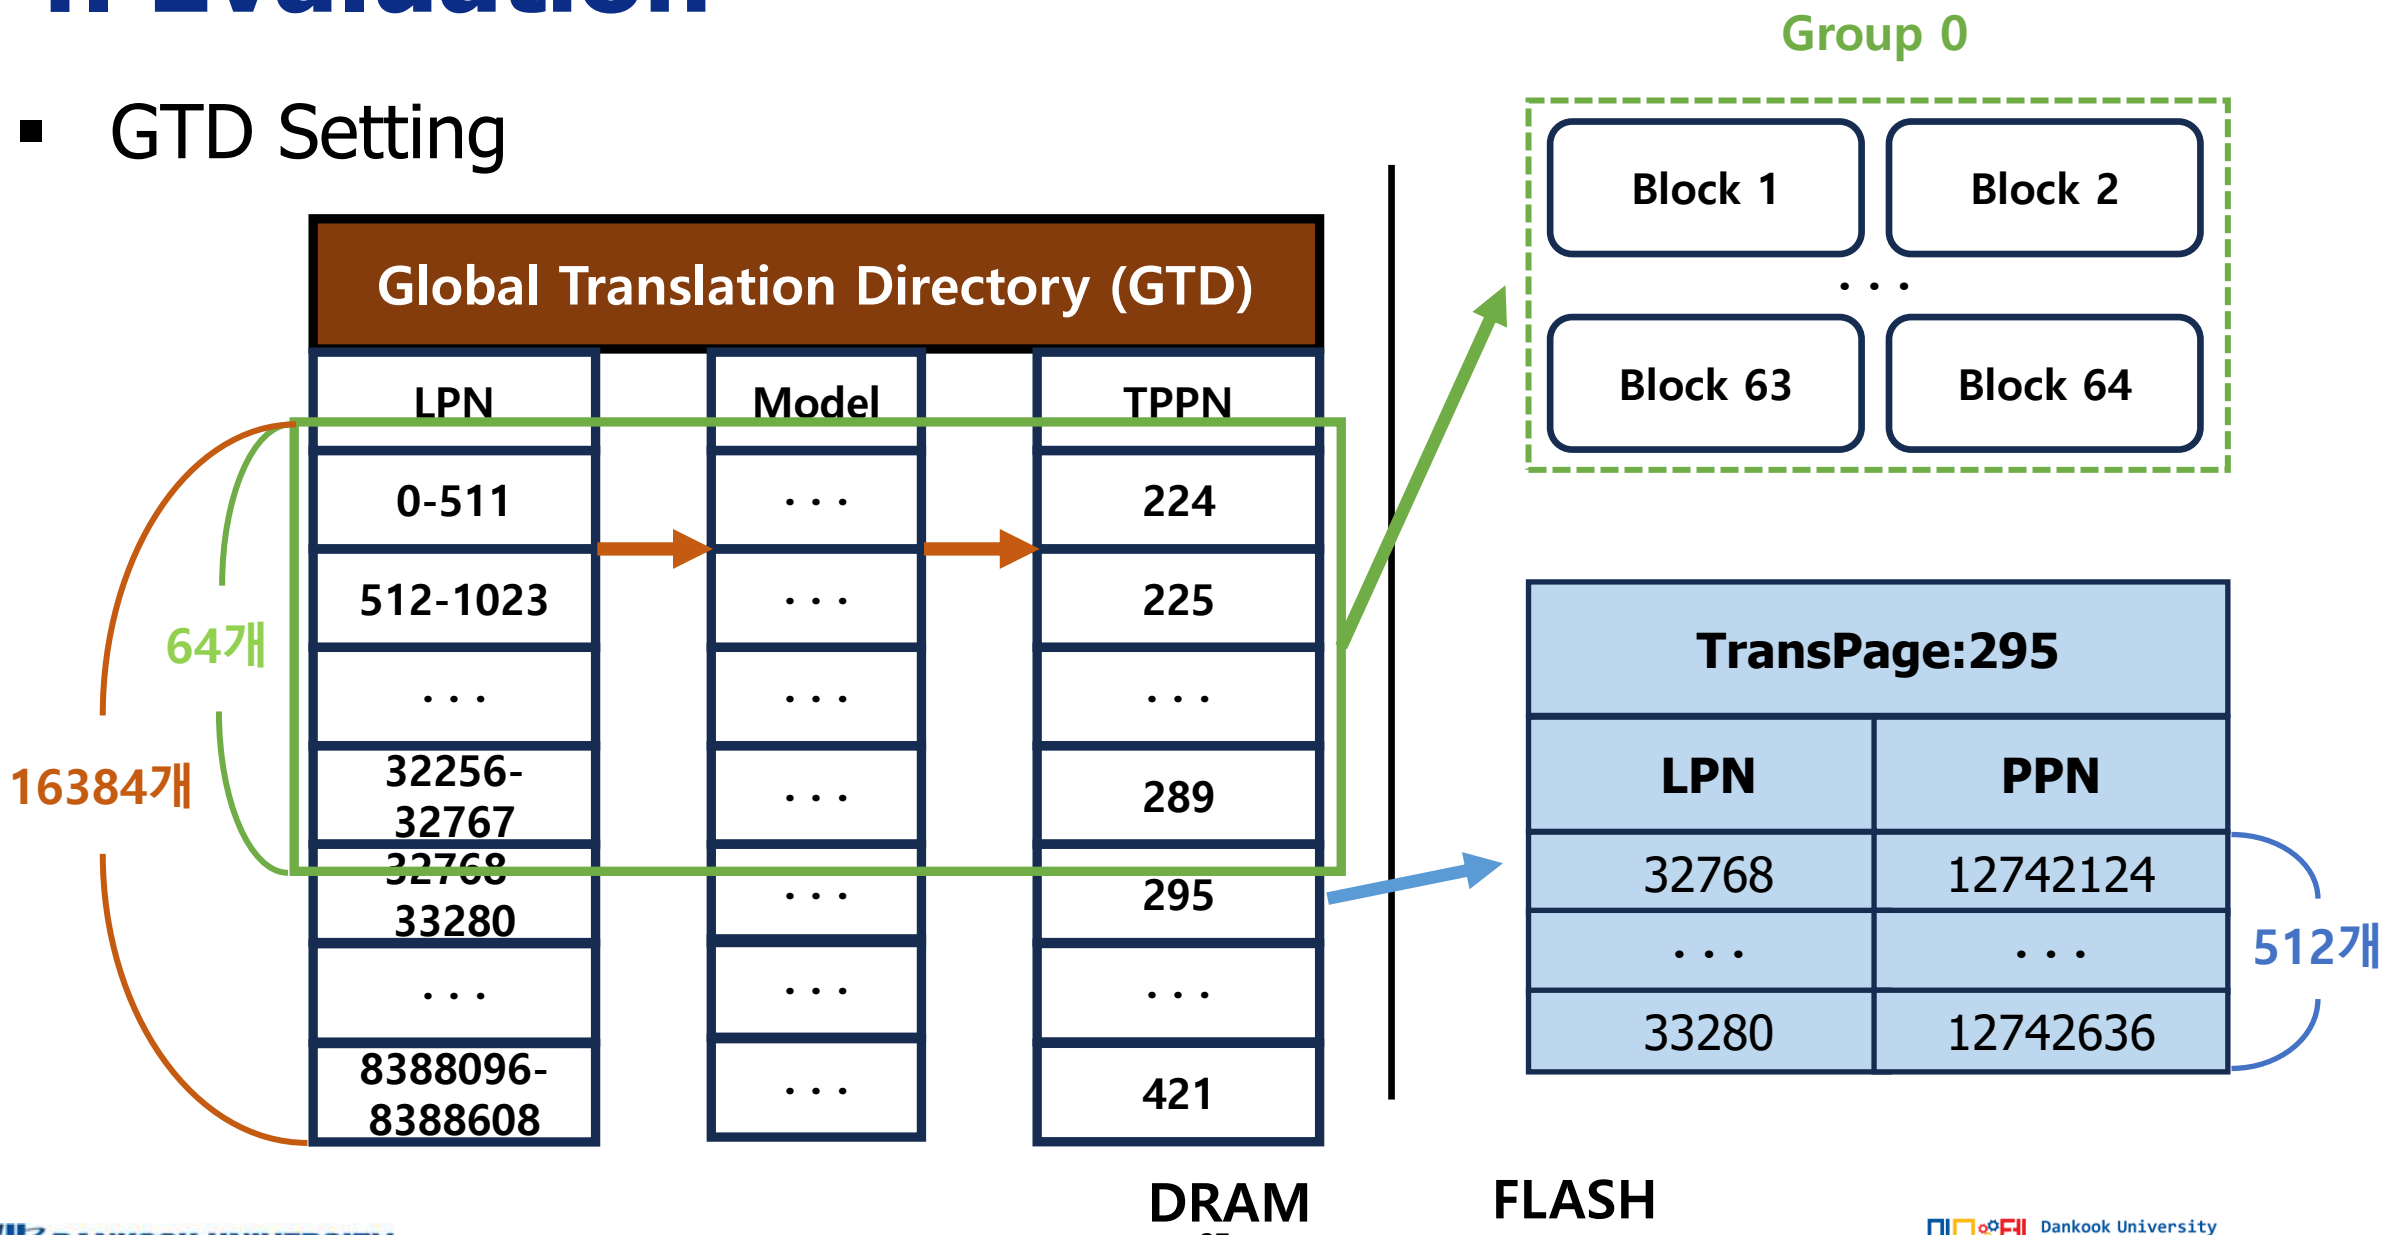

4. Evaluation

- **Read(FIO)**
  - Read 전 sequential/random write으로 워밍업
  - 4KB I/O size, psync I/O engine을 사용해 64개의 threads에서 읽기 실험 진행

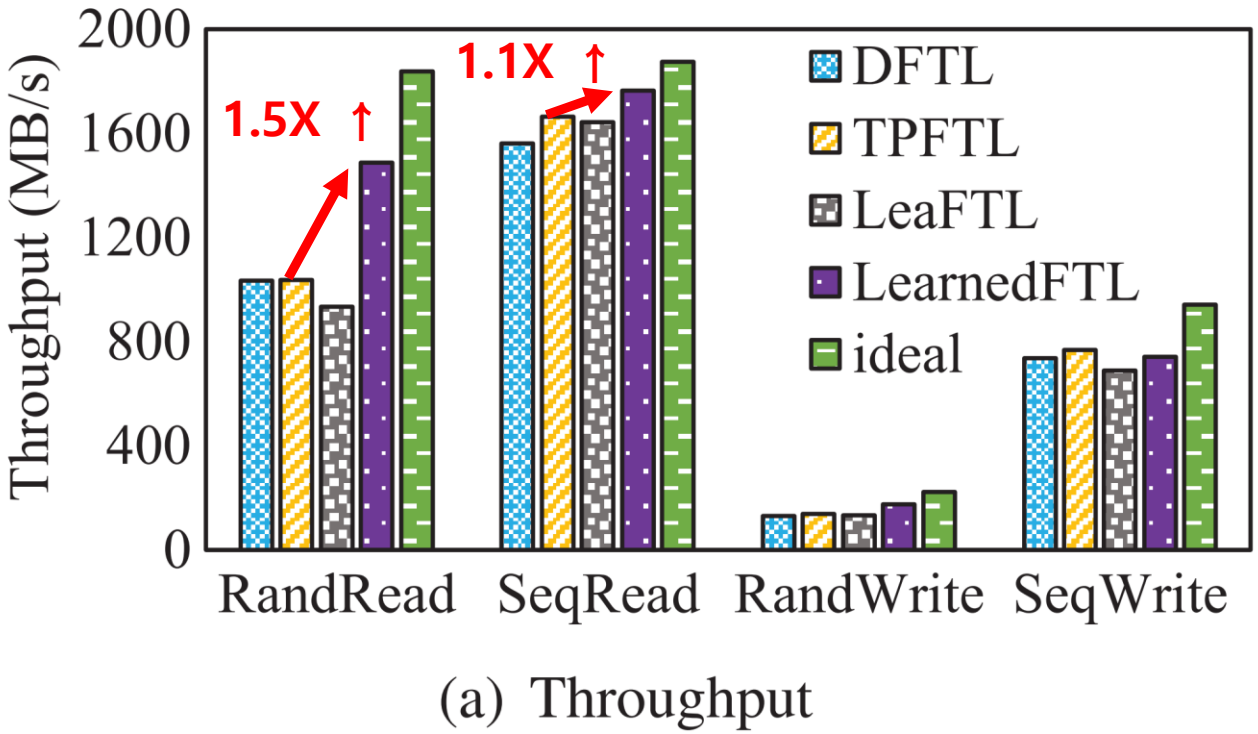

(a) Throughput

4. Evaluation

- **Read(FIO)**
  - Read 전 sequential/random write으로 워밍업
  - 4KB I/O size, psync I/O engine을 사용해 64개의 threads에서 읽기 실험 진행

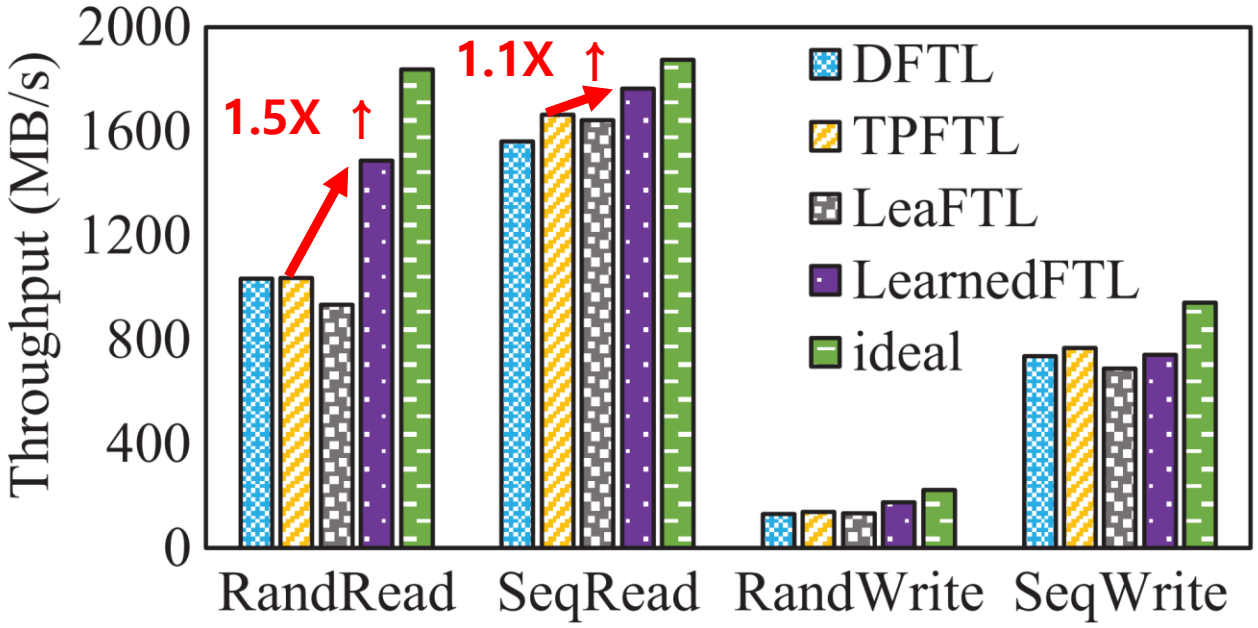

(a) Throughput

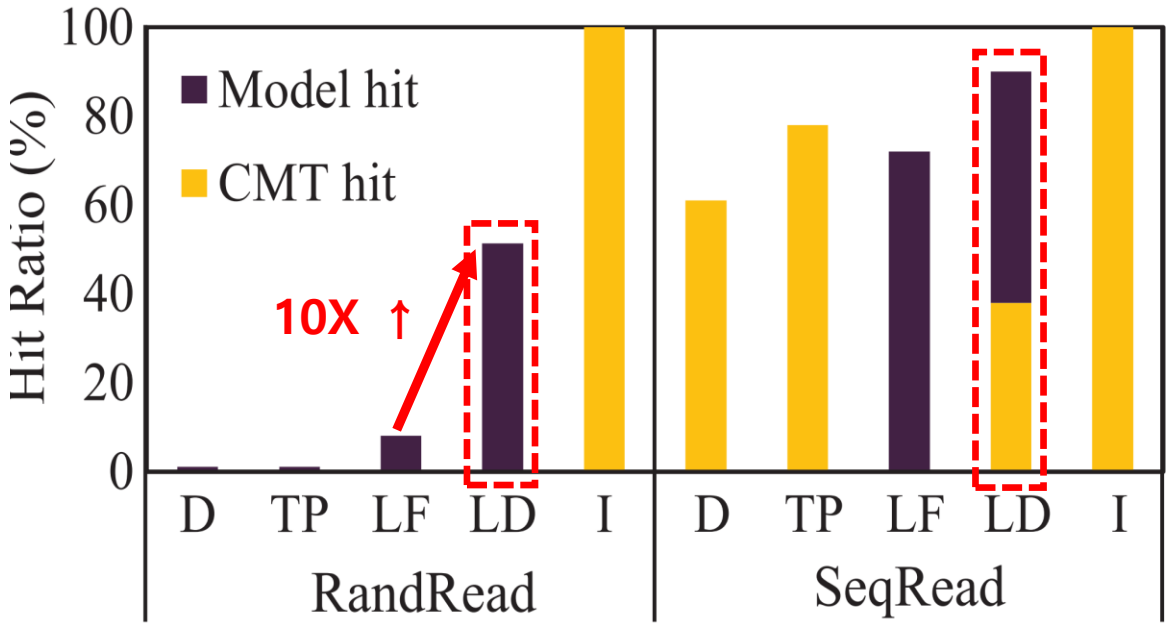

(b) Model and CMT hit ratio

4. Evaluation

- **Write(FIO)**
  - 4KB I/O size, psync I/O engine을 사용해 쓰기 실험 진행
  - Group-based allocation 방식을 사용해 다른 FTL보다 뛰어난 성능

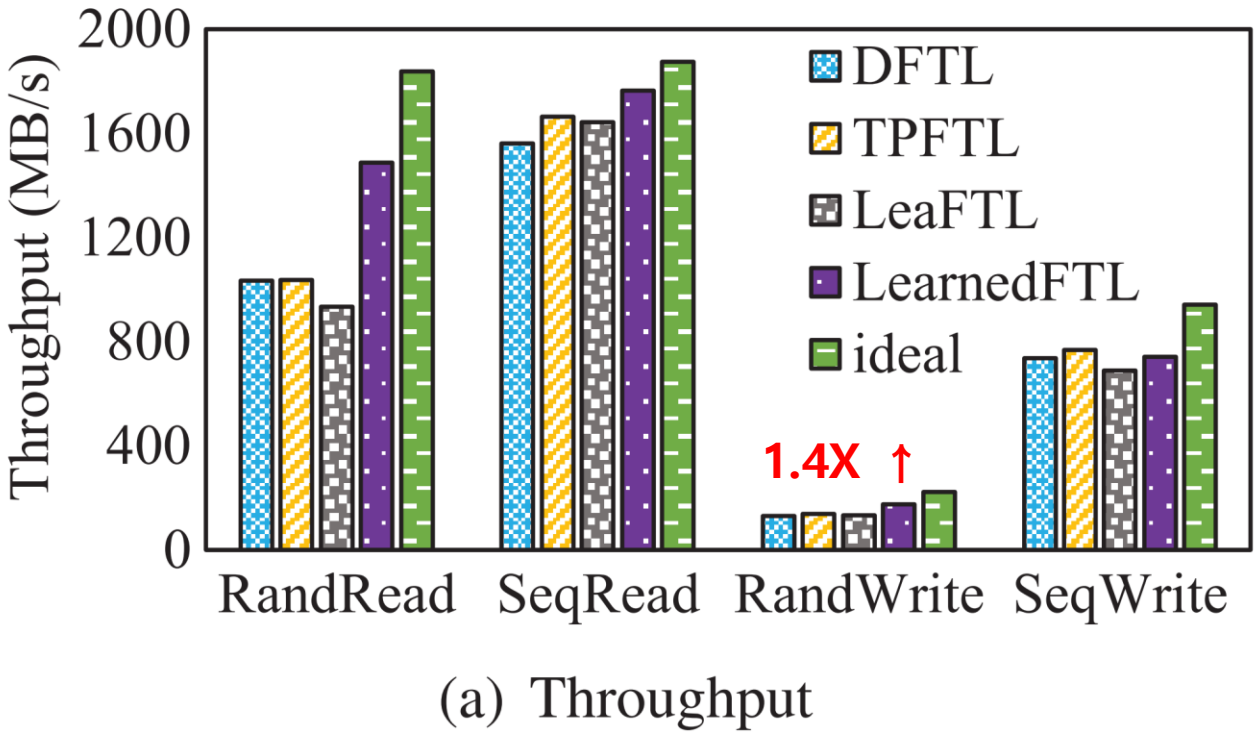

(a) Throughput

4. Evaluation

- **Write(FIO)**
  - 4KB I/O size, psync I/O engine을 사용해 쓰기 실험 진행
  - Group-based allocation 방식을 사용해 다른 FTL보다 뛰어난 성능

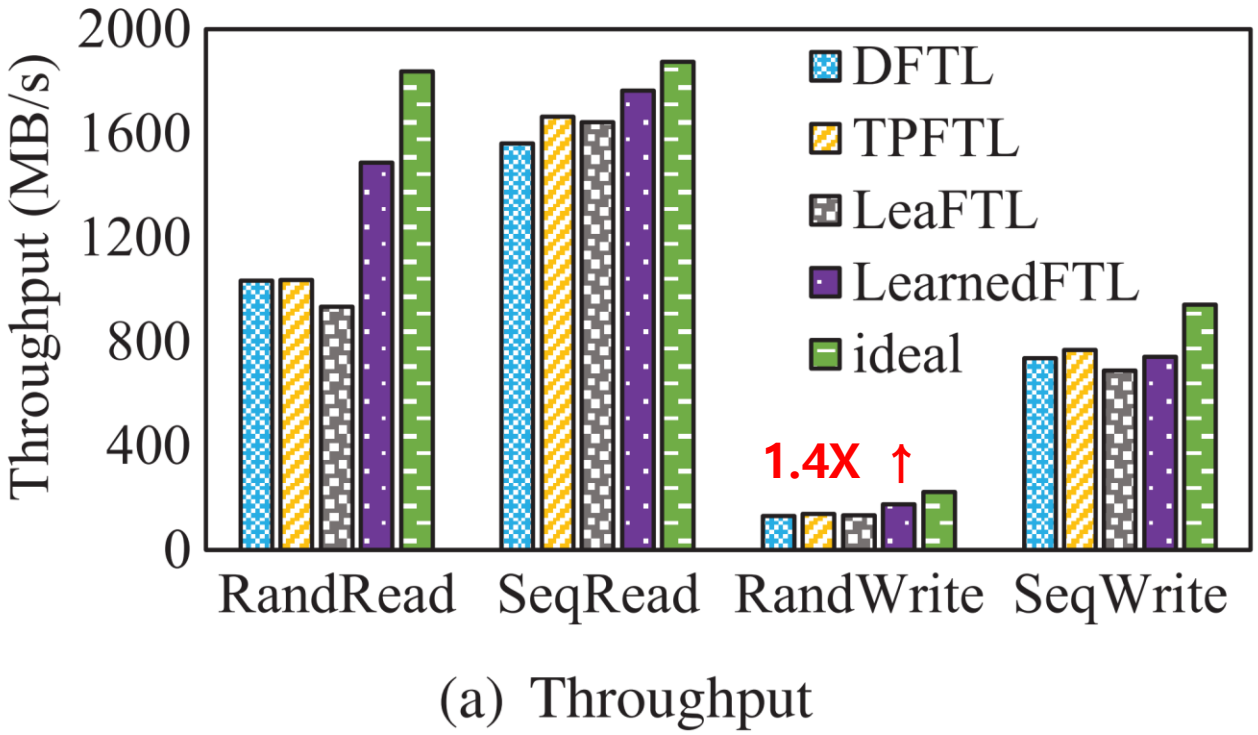

(a) Throughput

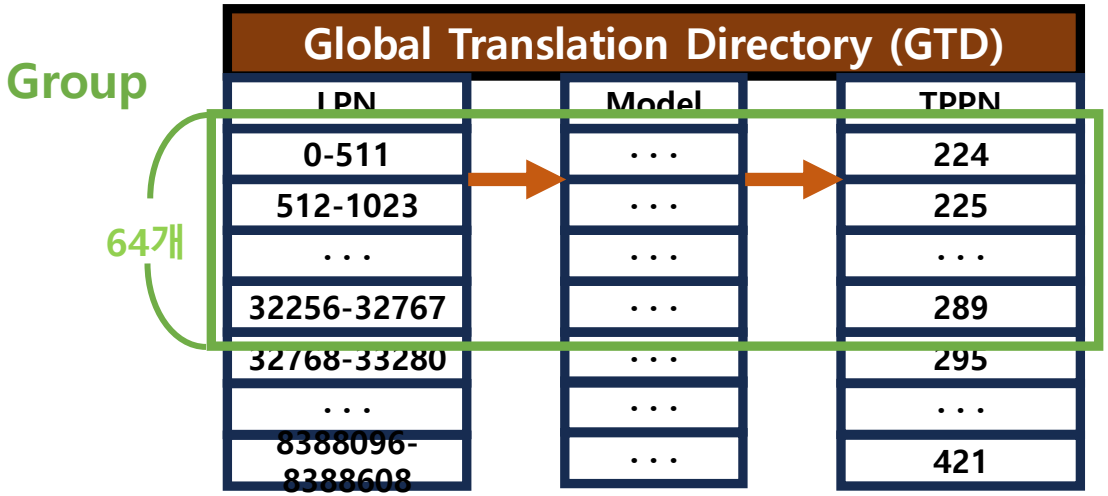

4. Evaluation

- **GC overhead**
  - 모델 훈련은 GC에서 이루어지며 group-based allocation 방식으로 트레이닝

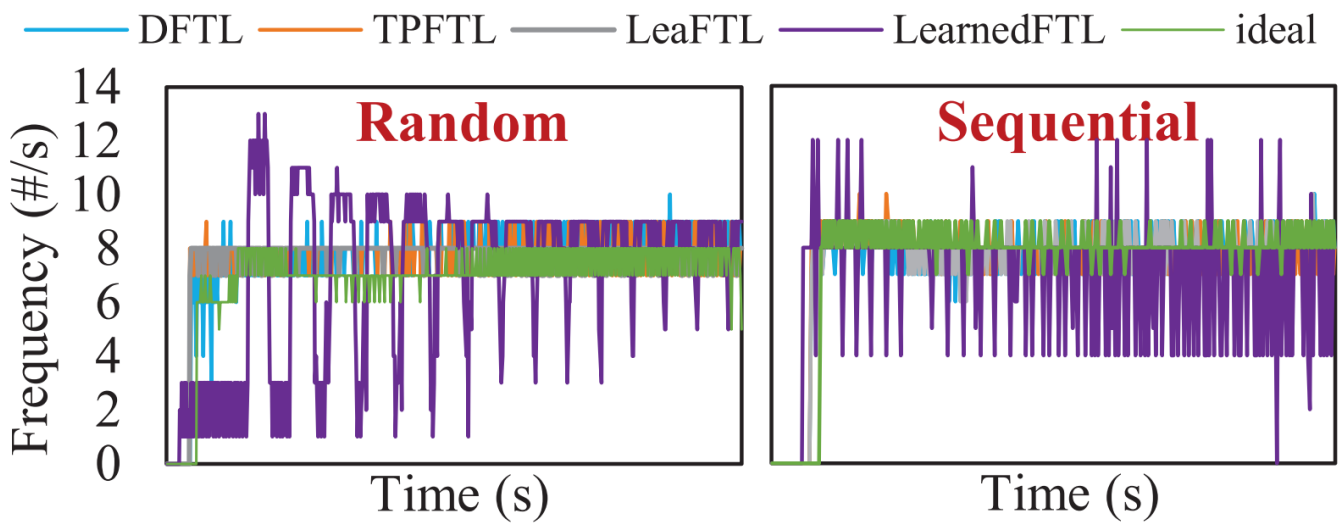

Write	Random	Sequential
DFTL	4335	4572
TPFTL	4335	4304
LeaFTL	4395	4473
LearnedFTL	4188	4285

Fig. 16: The GC frequency of all FTL designs under FIO random and sequential write benchmarks.

4. Evaluation

- **GC overhead**
  - 모델 훈련은 GC에서 이루어지며 group-based allocation 방식으로 트레이닝

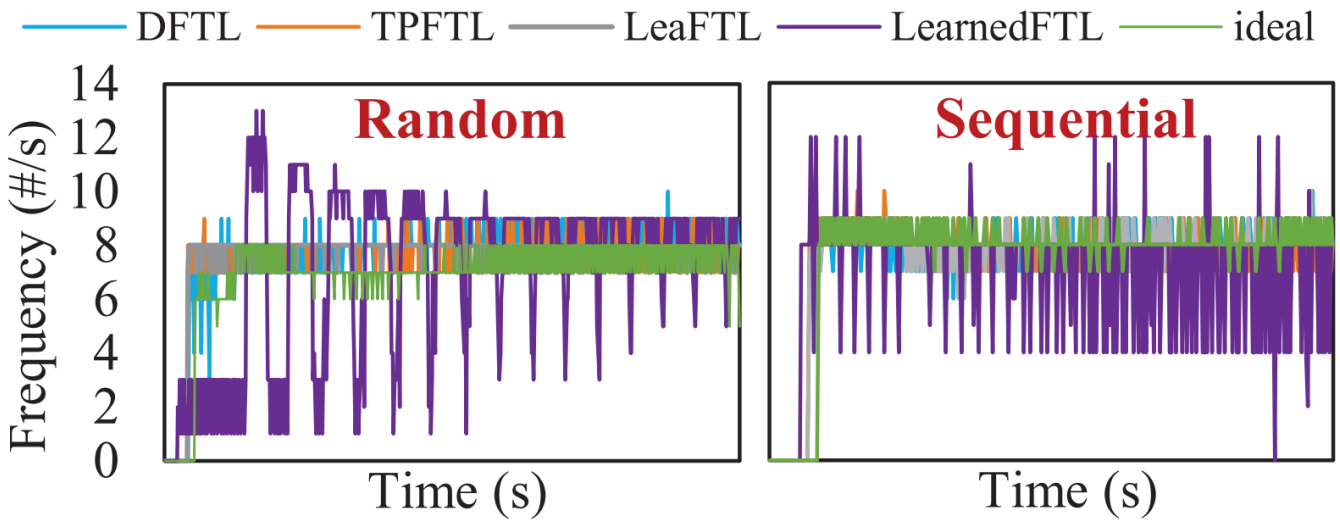

Fig. 16: The GC frequency of all FTL designs under FIO random and sequential write benchmarks.

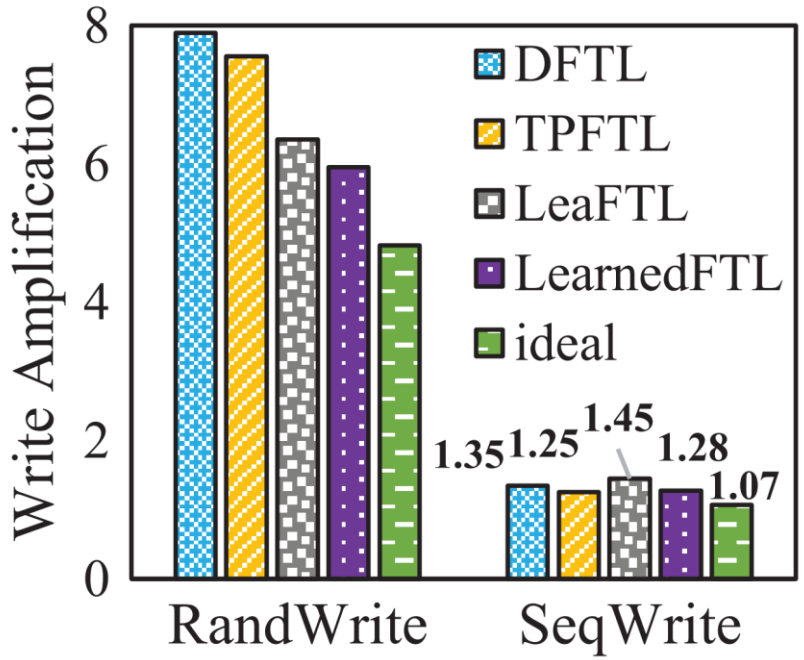

(c) Write amplification

4. Evaluation

- **Training and sorting overhead**
  - Model training & LPN-sorting
  - GC 동안 GTD entry group에 64개의 LPN을 정렬하고 트레이닝 작업이 트리거 된다.

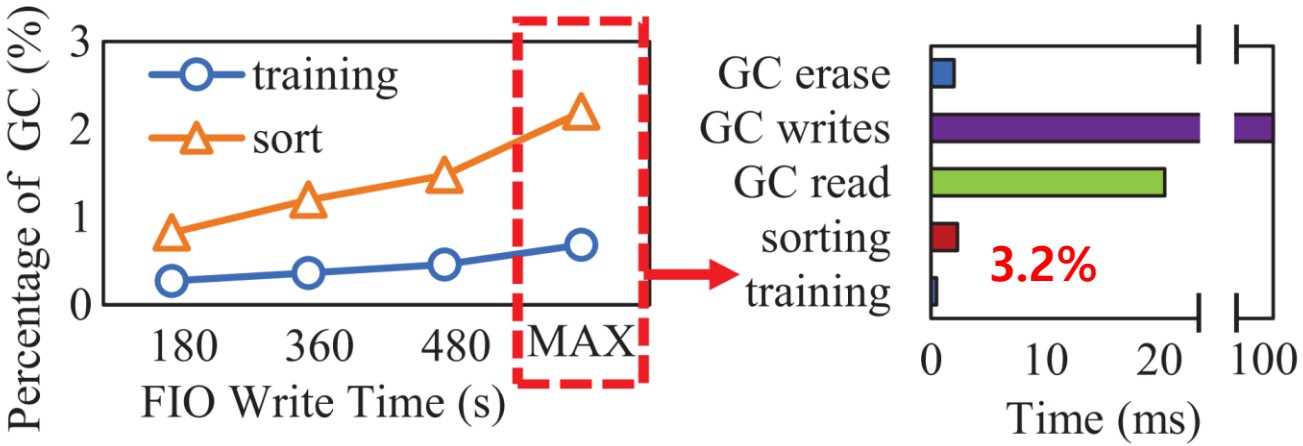

Fig. 17: The time overhead of sorting and training under different running times of FIO random writes (MAX means almost all pages are valid during GC).

4. Evaluation

- **Training and sorting overhead**
  - Model training & LPN-sorting
  - GC 동안 GTD entry group에 64개의 LPN을 정렬하고 트레이닝 작업이 트리거 된다.

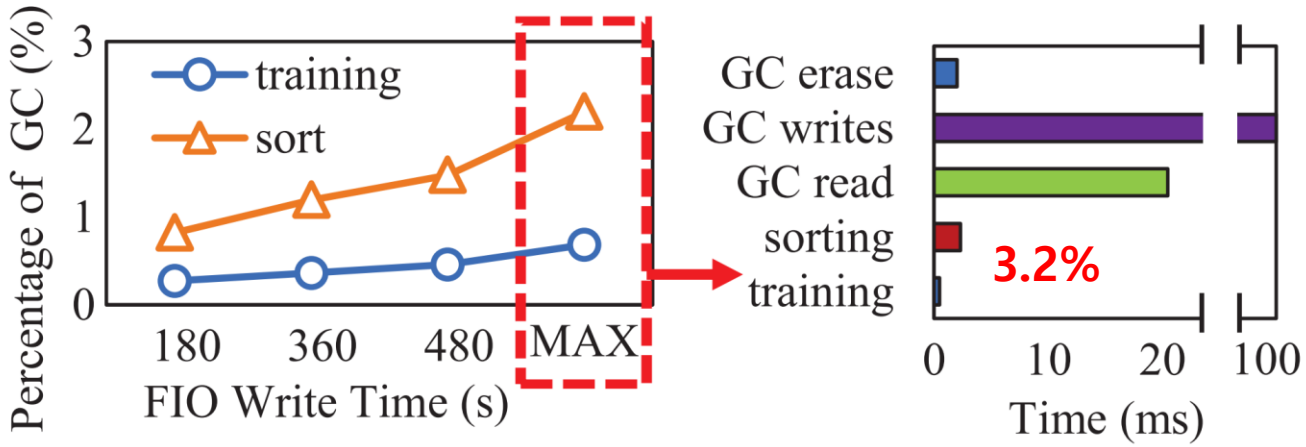

Fig. 17: The time overhead of sorting and training under different running times of FIO random writes (MAX means almost all pages are valid during GC).

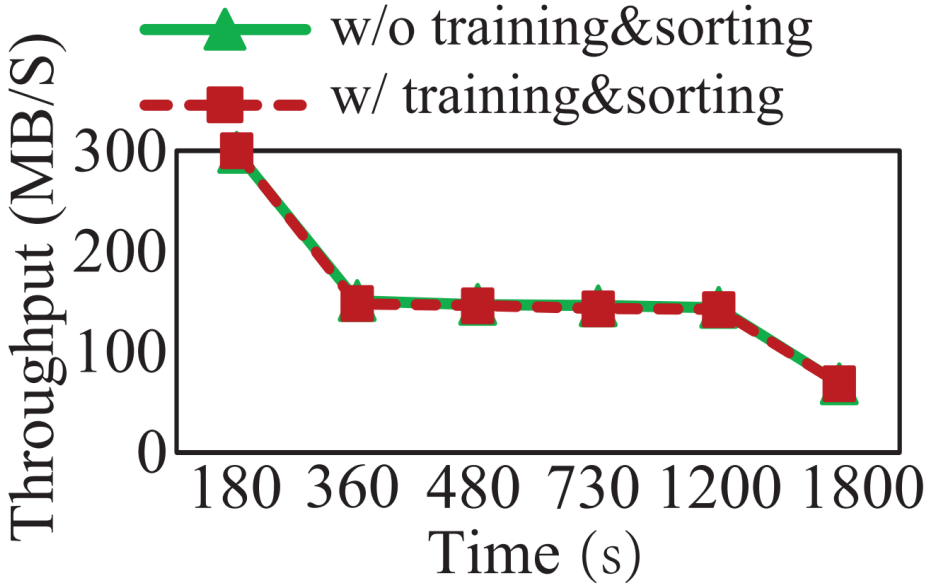

(a) Write and GC

4. Evaluation

- **Real-World Applications**
  - **RocksDB** evaluation with EXT4 filesystem
  - db_bench tool 사용(단일 스레드)

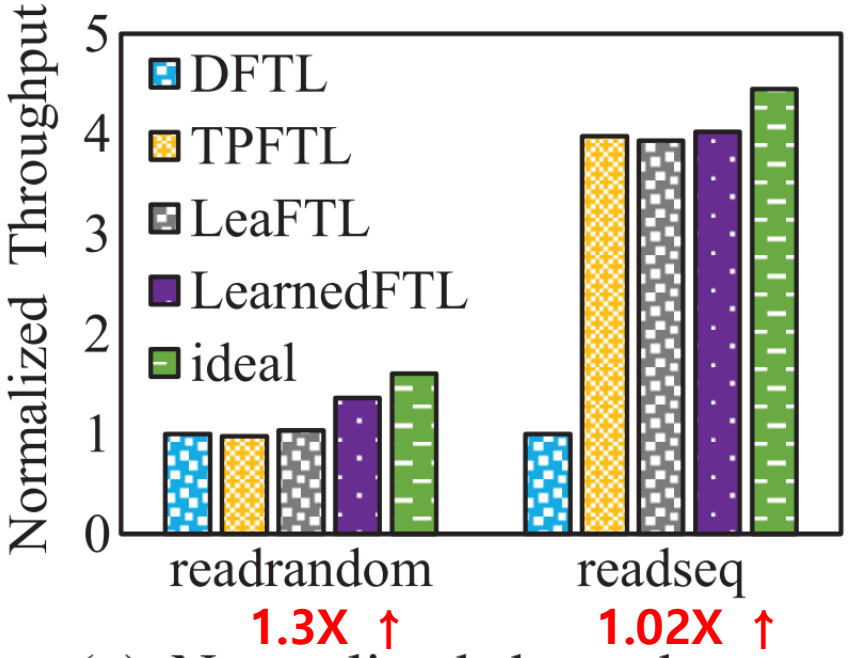

(a) Normalized throughput

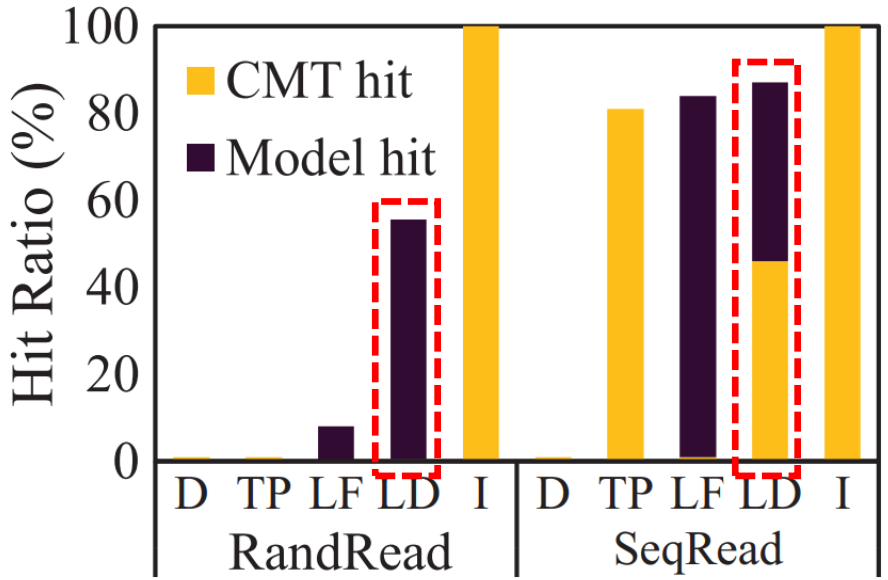

(b) CMT and model hit ratio

5. Conclusion

① Address translation 효율을 높이기 위해 learned index 사용

- Random read access에서 miss 시 발생하는 double read 감소
- In-place update linear model로 learned index를 효율적으로 사용

② 효율적인 model 학습을 위해 Virtual PPN을 사용

- 채널부터 페이지까지 고정된 수의 SSD 계층의 PPN 계산 순서를 변경
- 기존 연속적인 LPN에 불연속적인 PPN 대신 연속적인 PPN으로 구현 가능

③ Group-based allocation과 GC/rewrite를 통한 model training을 사용해 training overhead 감소

Thank you

LearnedFTL: A Learning-based Page-level FTL for Reducing Double Reads in Flash-based SSDs

Shengzhe Wang, Zihang Lin, Suzhen Wu, Hong Jian, Jie Zhang, Bo Mao

Computer Science and Engineering Department, University of Texas at Arlington, Arlington, TX, USA
*School of Computer Science, Peking University

2024 IEEE International Symposium on High-Performance Computer Architecture (HCPA)

Q&A

2024. 08. 07

Presentation by Kim MinSeong, Wee DaYeon

kms0509@dankook.ac.kr, wida10@dankook.ac.kr

DANKOOK UNIVERSITY

Dankook University System Software Laboratory